

Método de la ingeniería

Fase 1: Identificación del problema

Requerimientos funcionales

1. Generar mil millones de registros con los siguientes campos:
 - A) Código
 - B) Nombre
 - C) Apellido
 - D) Sexo
 - E) Fecha de nacimiento
 - F) Estatura
 - G) Nacionalidad
 - H) Fotografía
2. Mostrar una barra de progreso para indicar cuánto tiempo se demora la operación, en el caso tal que esta tenga un estimado mayor a un 1 segundo.
3. Indicar cuántos registros se quiere generar, a pesar de que el predeterminado sea el máximo posible.
4. Agregar nuevos registros al sistema
5. Guardar los registros que se agregaron o se generaron en el sistema.
6. Actualizar la información de un registro que el usuario desee cambiar.
7. Eliminar un registro existente en el sistema.
8. Consultar los registros de acuerdo a los siguientes criterios:
 - A) Nombre completo
 - B) Nombre
 - C) Apellido
 - D) Código
9. Mostrar una lista emergente debajo del campo de búsqueda, a medida que el usuario digite la información correspondiente (excepto para código). Esto, con la idea de hacer la búsqueda anteriormente mencionada.
10. Calcular y mostrar la cantidad total de elementos que coinciden con el prefijo digitado por el usuario.

Fase 2: Recopilación de la información necesaria

Para solucionar este problema tan importante, se requiere de una estructura que almacene eficientemente los datos: desde la lectura hasta la escritura, su velocidad debe de ser rápida. Además, se necesita evitar sobrecribir toda la información antes de que esta sea requerida. Es decir, un almacenamiento eficaz en general.

[Marco teórico esencial](#)

La definición de una estructura eficiente depende mucho del problema, en la búsqueda de información se encontraron diversas estructuras que se pueden utilizar dependiendo del tipo de dato que se almacena y el contexto del problema. Por ejemplo: para el caso de maximos y minimos se usan los monticulos; para la busqueda se usan arboles ABB, AVL, roji-negros y trie (estos se usan para almacenar Strings teniendo en cuenta todos los prefijos de una cadena).

[Información acerca del trie](#)

También es importante entender esta información desde otro ángulo. En pocas palabras, analizar los *requerimientos no funcionales*:

1. Cuando se generen los registros en el sistema, se debe de tomar los siguientes aspectos:
 - A) El código debe ser autogenerado con una cantidad específica de caracteres.
 - B) La estatura debe de estar en un intervalo conceptual (se asemeje a lo real).
 - C) La fecha de nacimiento debe de estar distribuida según lo indicado.
 - D) Los nombres y apellidos deben ser tomados del dataset.
 - E) Se debe de combinar aleatoriamente cada nombre y/o apellido del dataset.
2. Todos los dataset utilizados en el sistema deben de estar en un directorio llamado “data”.
3. Las fotografías utilizadas para completar el perfil requerido del sistema, deben ser tomadas del siguiente sitio: [oficial numero uno](#)
4. La proporción de edades debe seguir la siguiente distribución: [oficial numero dos](#)
5. Las proporciones de cada nacionalidad deben estar acorde a los datos de población del siguiente enlace: [oficial número tres](#)
6. La interfaz gráfica debe ser realizada con JavaFx.
7. Toda la información existente del sistema debe ser persistente.

8. Si se agrega o se actualiza un registro, el usuario no tendrá la opción de modificar el código del registro, ya que este debe ser autogenerado.
9. La lista emergente debe mostrar máximo 100 nombres parametrizables, los cuales deben empezar con los caracteres digitados hasta el momento.
10. Las búsquedas realizadas se deben manejar en un árbol ABB autobalanceado, el cual debe de tener una implementación propia.
11. Implementar adecuadamente las pruebas unitarias automáticas de las estructuras propias y de las operaciones principales del modelo
12. La interfaz gráfica tendrá un menú superior en la ventana, el cual permite cambiar todos los elementos cuando se esté trabajando en opciones diferentes.

Con base en estos requerimientos funcionales y no funcionales, es evidente que se necesita de una estructura eficiente en cuanto a todas las operaciones, principalmente en la operación de búsqueda (será escogida en la etapa de diseño).

Por otro lado, dentro de los requerimientos se establece que la información debe ser persistente. Entonces, se propone las dos siguientes ideas: La primera funciona por medio de archivos de texto planos, que permite almacenar todos los atributos en forma de texto. Y la segunda es usando serialización, que faculta almacenar objetos completos sin necesidad de guardar cada atributo.

Fase 3: Búsqueda de soluciones creativas

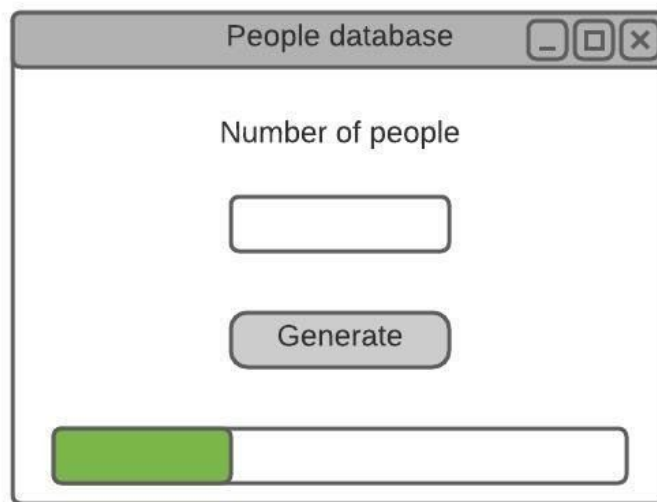
Para realizar esta etapa tan importante para el proyecto, se tomaron dos iniciativas importantes:

- Tomar la lluvia de ideas para la generación de ideas espontáneas que permitan resolver el problema de forma correcta y significativa.
- Dominar la lista de atributos para entender y visualizar todas las características o atributos especiales que puede tener el software en general.

Para la primera parte de estas soluciones planteadas, se utiliza la herramienta Google docs, ya que esta nos permite plasmar de forma ordenada y calibrada todas las gestiones individuales y/o grupales que puede tener el proyecto informático. En base a esta plataforma utilizada, definimos ciertas estrategias y estructuras que van acorde al planteamiento del problema. Es importante aclarar que cada búsqueda planteada va directamente asimilada con una estructura de datos. Estas pueden ser:

- Árbol Binario de búsqueda (ABB)
- Arbol AVL
- Trie
- Arbol roji - negro
- Lista enlazada
- Lista enlazada ordenada
- Arreglo
- Arreglo ordenado
- HashTable

Tomando en cuenta estas estructuras planteadas, vemos de una manera base los diseños de interfaz gráfica. Estos son los que verá el usuario al momento de utilizar el programa y ejecutarlo en su sistema:



The image shows a window titled "People database" with standard window controls (minimize, maximize, close). Inside the window, there is a label "Number of people" above a text input field. Below the input field is a button labeled "Generate". At the bottom of the window is a progress bar with a green segment on the left and a white segment on the right.

People database

Name of the person

Search

People database

Name

Last name

Gender

Height

Nationality

Add

People database

Name of the person

Change information

También es importante destacar que para la generación de edades y del género de la persona, tomando en cuenta la proporción de Estados Unidos obtenemos lo siguiente:

- Usar el método `Math.random()` para obtener un número entre 0 y 1, y así, ser distribuido de acuerdo a los intervalos proporcionales. Por ejemplo: si la proporción de personas entre 0-20 años es del 25% y el método retorna un valor entre 0 y 0.25, se le asigna una edad a las personas que estén en este rango.

Además, para las nacionalidades se sigue un razonamiento similar al anterior, donde se divide en intervalos los números entre 0 y 1, donde cada intervalo le corresponde una nacionalidad. El tamaño de cada intervalo corresponde a la proporción de la población de cada país americano. Ejemplo: Si la proporción de colombianos en América es del 5% el intervalo debe tener un tamaño de 0.05.

Por último, planteamos ideas para la solución a la funcionalidad de predicción en resultados de búsqueda, estos tomados por los atributos de nombre, nombre completo y apellido.

- Con el método “on key typed” por parte de la clase `TextField` de `JavaFX`, podemos realizar alguna acción con cada letra digitada por el usuario. Es decir, el sistema reconocerá cada letra escrita sin necesidad de utilizar el botón constantemente.
- A medida que se escribe, se busca un nodo que tenga el nuevo caracter agregado. Esto, con la idea de desplegar los elementos que se encuentren por debajo del mismo en el caso de `Trie`. EL uso del `trie` se limitaría a la predicción de la búsqueda pero la obtención del objeto con el valor buscado sería de las estructuras donde se almacenan de acuerdo a cada criterio.
- Con la información ingresada por el usuario hasta cierto momento, buscar las personas que contengan su nombre, apellido para mostrarlos en la lista de búsqueda implementada para la solución eficaz del software.

Fase 4: Transición de la formulación de ideas a los diseños preliminares

Tomando en cuenta la fase anterior en el método de la ingeniería, obtenemos las candidatas para analizarlas y trabajarlas de forma más específica:

- Utilizar trie en el sistema, ya que resulta ser una estructura eficaz para lo que estamos buscando solucionar: la información almacenada aquí es un conjunto de claves, donde una clave es una secuencia de símbolos pertinentes a un alfabeto. El árbol se estructura de forma que cada letra de la clave se sitúa en un nodo de forma que los hijos de un nodo representan las distintas posibilidades de símbolos diferentes que pueden continuar al símbolo representado por el nodo padre.

[Marco teórico utilizado para la herramienta.](#)

- Usar árboles AVL, ya que estos están siempre equilibrados de tal modo que para todos los nodos, la altura de la rama izquierda no difiere en más de una unidad de la altura de la rama derecha o viceversa. Gracias a esta forma de equilibrio (o balanceo), la complejidad de una búsqueda en uno de estos árboles se mantiene siempre en orden de complejidad $O(\log n)$.

[Información utilizada para mayor entendimiento de la estructura.](#)

- Los árboles roji - negros resultan extremadamente factibles, ya que ofrecen un peor caso con tiempo garantizado para la inserción, el borrado y la búsqueda. No es esto únicamente lo que los hace valiosos en aplicaciones sensibles al tiempo como las aplicaciones en tiempo real, sino que además son apreciados para la construcción de bloques en otras estructuras de datos que garantizan un peor caso.

[En este sitio web se puede visualizar de forma correcta esta estructura.](#)

- El uso de la estructura de datos HashTable no es factible para los criterios de búsqueda que requieran implementar la función de autocompletar, pues la búsqueda de un elemento que se encuentre en ella tiene una complejidad temporal de $O(1)$ y, aunque esto es muy eficiente, no permite predecir los resultados de búsqueda. Sin embargo, la operación de búsqueda por código no requiere esta función, así que puede resultar útil manejarla con una HashTable.
- El uso de arreglos y listas enlazadas se descarta debido a que no son eficientes para buscar ni eliminar. Las listas enlazadas podrían agregar en $O(1)$ pero no tiene utilidad si el buscar o eliminar tardan mucho más ($O(n)$) en ambas estructuras. Se podrían mantener ordenadas lo que volviera el buscar en $O(\log n)$ usando búsqueda binaria pero agregar e eliminar sería $O(n)$.

Nota: No se analizan las propuestas de solución los demás sub problemas, debido a que en todos los casos sólo hay una idea que resultante de la lluvia de ideas.

Fase 5: Selección y evaluación de la mejor solución

Siendo M el tamaño de la entrada (String), k el tamaño promedio de una String en el trie, y n el número de datos en la estructura:

Estructura	Complejidad Temporal (caso promedio)			Complejidad Temporal (Peor caso)			Complejidad Espacial (Espacio usado por la estructura)
	Inserción	Eliminación	Búsqueda	Inserción	Eliminación	Búsqueda	
ABB	$O(\log n)$	$O(\log n)$	$O(\log n)$	$O(n)$	$O(n)$	$O(n)$	$O(n)$
AVL	$O(\log n)$	$O(\log n)$	$O(\log n)$	$O(\log n)$	$O(\log n)$	$O(\log n)$	$O(n)$
Trie	$O(M)$	$O(M)$	$O(M)$	$O(M)$	$O(M)$	$O(M)$	$O(kn)$
Hash Table	$O(1)$	$O(1)$	$O(1)$	$O(n)$	$O(n)$	$O(n)$	$O(n)$
Arbol roji negro	$O(\log n)$	$O(\log n)$	$O(\log n)$	$O(\log n)$	$O(\log n)$	$O(\log n)$	$O(n)$

Las evaluación que consideramos importantes son:

- Trie para la predicción de resultados de búsqueda: Se inicia en el root del árbol; Si el símbolo que estamos buscando es A entonces la búsqueda continúa en el subárbol asociado al símbolo A que cuelga de la raíz. Se sigue de forma análoga hasta llegar al nodo hoja. Entonces se compara la cadena asociada a el nodo hoja y si coincide con la cadena de búsqueda entonces la búsqueda ha terminado en éxito, si no entonces el elemento no se encuentra en el árbol.
- AVL para nombre y apellido: El factor de equilibrio puede ser almacenado directamente en cada nodo. Para conseguir esta propiedad de equilibrio, la inserción y el borrado de los nodos se ha de realizar de una forma especial. Si al realizar una operación de inserción o borrado se rompe la condición de equilibrio, hay que realizar una serie de rotaciones.
- Roji - negro para el nombre completo: A pesar de que resulta atractiva y eficaz la idea de utilizar esta estructura para alguna busqueda, no la implementaremos por dos razones fundamentales:
 1. El tiempo estimado de entrega, junto a las obligaciones y funcionalidades básicas hacen que no esté en una mayor prioridad.
 2. Debido a la cantidad de datos que debemos de utilizar, preferimos evitar algún inconveniente.

- Hash Table para el código: La búsqueda es muy rápida en promedio. Muy pocas veces será $O(n)$ porque los objetos se distribuyen de igual forma por todo el arreglo minimizando las colisiones.

Fase 6: Preparación de informes y especificaciones

[Diagrama de clases](#) / [Diagrama de pruebas](#)

Fase 7: Implementación del diseño

[Ver repositorio en GitHub](#)